

Klasifikasi Citra Ikan Menggunakan Algoritma Convolutional Neural Network dengan Arsitektur VGG-16

Imam Muslem R*, T M Johan, Luthfi

Fakultas Ilmu Komputer, Program Studi Informatika, Universitas Almuslim, Bireuen, Indonesia

Email: ¹*imamtkj@email.com, ²johanpeusangan@email.com, luthfi2048@email.com

Email Penulis Korespondensi: imamtkj@email.com

Abstrak—Pengembangan teknologi dalam bidang pengolahan citra telah menginspirasi penelitian ini yang bertujuan untuk mengatasi tantangan dalam klasifikasi citra ikan menggunakan pendekatan berbasis Convolutional Neural Network (CNN). Dalam penelitian ini, kami memanfaatkan arsitektur VGG-16, sebuah model CNN yang telah terbukti mampu mengambil fitur-fitur penting dari citra dengan kedalaman yang signifikan. Dataset terdiri dari 1088 citra ikan yang dibagi menjadi empat kelas: Bangus, Glass Perchlet, Gold Fish, dan Gourami. Proses awal melibatkan ekstraksi fitur melalui image embedding menggunakan arsitektur VGG-16. Selanjutnya, model klasifikasi dibangun dengan memanfaatkan tool Orange Data Mining. Hasil eksperimen menunjukkan bahwa pendekatan ini mampu memberikan kinerja klasifikasi yang baik dengan akurasi yang signifikan dalam mengenali jenis-jenis ikan yang berbeda. Penggunaan VGG-16 memungkinkan ekstraksi fitur yang kuat dan kompleks, dan hasil eksperimen menunjukkan bahwa pendekatan ini berhasil mencapai akurasi training sebesar 96,2%. Selanjutnya, saat proses klasifikasi menggunakan data testing, metode ini menghasilkan akurasi sebesar 99,5%. Temuan ini menunjukkan potensi besar Convolutional Neural Network dalam mengatasi tantangan klasifikasi citra ikan dengan hasil yang sangat memuaskan, yang dapat diaplikasikan dalam berbagai bidang termasuk ilmu kelautan dan penginderaan jauh.

Kata Kunci: Klasifikasi Citra Ikan; Convolutional Neural Network; Arsitektur VGG-16; Akurasi Klasifikasi; Analisis Citra

Abstract—The development of technology in the field of image processing has inspired this research which aims to overcome challenges in classifying fish images using a Convolutional Neural Network (CNN) based approach. In this research, we utilize the VGG-16 architecture, a CNN model that has been proven capable of retrieving important features from images with significant depth. The dataset consists of 1088 fish images divided into four classes: Bangus, Glass Perchlet, Gold Fish, and Gourami. The initial process involves feature extraction via image embedding using the VGG-16 architecture. Next, a classification model is built using the Orange Data Mining tool. The experimental results show that this approach is able to provide good classification performance with significant accuracy in recognizing different fish species. The use of VGG-16 enables powerful and complex feature extraction, and experimental results show that this approach achieves a training accuracy of 96.2%. Furthermore, when the classification process uses data testing, this method produces an accuracy of 99.5%. This finding shows the great potential of the Convolutional Neural Network in overcoming the challenge of classifying fish images with very satisfactory results, which can be applied in various fields including marine science and remote sensing.

Keywords: Image Classification of Fish; Convolutional Neural Networks; VGG-16 Architecture; Classification Accuracy; Image Analysis.

1. PENDAHULUAN

Salah satu teknologi yang banyak digunakan dalam industri 4.0 yaitu teknologi computer vision [1]. Teknologi computer vision atau sering juga dikenal dengan image processing merupakan suatu teknologi pengolahan yang dapat dilakukan komputer berdasarkan citra yang ditangkap melalui kamera [2]. Teknologi ini banyak digunakan pada aplikasi robotika untuk menggantikan sensor dalam melakukan penginderaan [3], [4]. Hal ini dikarenakan sensor yang umumnya digunakan pada aplikasi berbasis robotika memiliki kelemahan dalam segi biaya implementasi tiap unit produknya, berbeda halnya dengan teknologi komputer vision yang hanya membutuhkan biaya pengembangan teknologinya saja, namun tidak diperlukan biaya implementasi hardware untuk tiap unit produknya [5].

Pengembangan teknologi kecerdasan buatan dalam hal ini yaitu teknologi yang berbasis image processing juga diperlukan untuk mengatasi berbagai kelemahan indera manusia, seperti dalam hal membedakan warna, membedakan bentuk benda, hingga melakukan klasifikasi dan pengelompokan terhadap objek-objek tertentu [6]. Pada dasarnya teknologi tersebut sudah banyak dikembangkan, misalnya seperti teknologi Brake Assist pada mobil keluaran terbaru yang mampu membantu pengereman otomatis apabila sensor mendeteksi objek dalam radius atau jarak tertentu [7]–[11]. Namun teknologi seperti ini tentu kurang efisien dalam penggunaannya dikarenakan teknologi tersebut masih menggunakan perangkat keras sensor yang harganya mahal dan harus dipakai pada setiap unit mobil yang diproduksi dan untuk setiap teknologi yang disematkan. Hal ini tentu berbeda apabila teknologi Brake Assist yang dikembangkan tidak menggunakan perangkat keras sensor, namun hanya menggunakan perangkat kamera beresolusi tinggi untuk mendeteksi objek yang ada di depan mobil, sehingga berdasarkan penginderaan tersebut, sistem kontrol dapat memberikan sinyal untuk mengaktifkan mekanisme Brake Assist [12]–[15]. Efisiensi yang dapat dilakukan tidak hanya sampai disitu, namun dengan satu unit perangkat kamera yang digunakan, dapat dikembangkan lagi teknologi berbeda, misalnya seperti video recording dengan menggunakan kamera yang sama dengan kamera Brake Assist, teknologi objek detection yang menggunakan kamera yang sama dengan sistem Brake Assist, teknologi pedestrian detection yang menggunakan kamera yang sama dengan sistem Brake Assist, teknologi Lane Departure Warning yang menggunakan kamera yang sama dengan sistem Brake Assist, dimana teknologi Lane Departure Warning dapat memberikan peringatan kepada pengemudi apabila mobil sudah keluar dari jalur utama, dan berbagai teknologi keselamatan lainnya yang dapat dikembangkan hanya

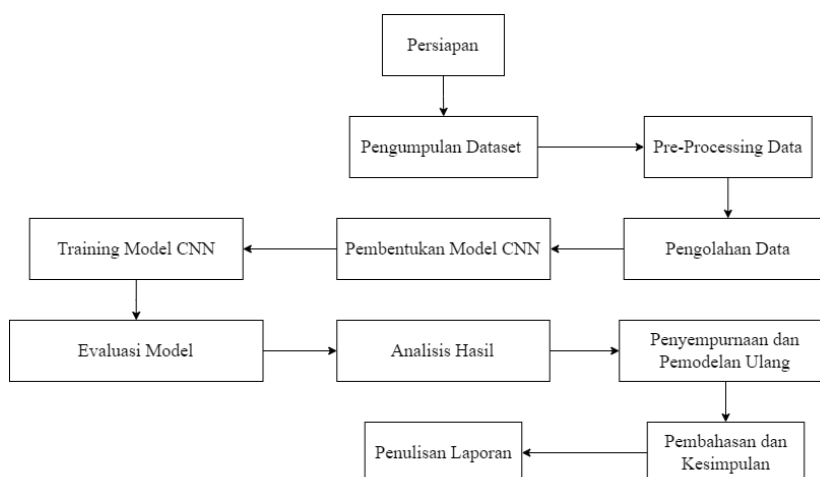
menggunakan satu perangkat keras saja, yaitu kamera beresolusi tinggi [16], [17]. Hal ini tentu berbeda apabila menggunakan perangkat keras sensor yang mengharuskan penggunaan lebih dari satu perangkat keras sensor untuk beberapa teknologi yang disematkan. Misalnya teknologi Brake Assist membutuhkan setidaknya satu unit sensor ultrasonik untuk mengindra objek, satu unit sensor untuk Lane Departure Warning, satu unit sensor untuk mendeteksi pejalan kaki, dan lain sebagainya [18], [19].

Teknologi tersebut tentu dikembangkan berdasarkan serangkaian tahapan penelitian yang dilakukan, salah satunya yaitu penelitian yang diusulkan ini. Adapun penelitian yang diusulkan ini bertujuan untuk melakukan analisis dan pengembangan sistem klasifikasi berdasarkan citra menggunakan algoritma Convolutional Neural Network (CNN) dengan arsitektur VGG-16 [20], [21]. Tujuannya yaitu untuk melakukan analisis dan klasifikasi terhadap citra ikan untuk mengelompokkan citra ikan berdasarkan jenisnya. Dataset yang digunakan dalam penelitian ini yaitu 4000 citra ikan yang dikumpulkan dari sumber terbuka. Adapun jenis ikan yang digunakan dalam penelitian ini adalah Bangus (171 foto), Glass Perchlet (399 foto), Gold Fish (201 foto) dan Gourami (312 foto). Adapun urgensi penelitian ini yaitu untuk melakukan analisis dan mengukur akurasi klasifikasi citra menggunakan arsitektur VGG-16 dengan dataset yang berjumlah 1088 data dengan 4 buah label.

2. METODOLOGI PENELITIAN

2.1 Tahapan Penelitian

Penelitian ini dilakukan dengan tujuan untuk membangun model klasifikasi citra ikan menggunakan metode Convolutional Neural Network dengan arsitektur VGG-16. Adapun tahapan penelitian yang dilakukan dapat dilihat pada gambar berikut:



Gambar 1. Tahapan Penelitian

- Pengumpulan Data, dimana pada tahap ini 1088 data citra ikan dikumpulkan dari berbagai sumber yang berbeda. Pada tahap ini juga dilakukan pembagian data citra menjadi empat kategori, yaitu Bangus, Glass Perchlet, Gold Fish, dan Gourami. Pada tahap ini juga dilakukan penyusunan dataset dengan membagi citra-citra ini ke dalam masing-masing label.
- Pra-pemrosesan Data, dimana pada tahap ini dilakukan resizing terhadap citra-citra agar memiliki ukuran yang konsisten. Pada tahap ini juga dilakukan normalisasi nilai pixel citra untuk mengurangi perbedaan skala.
- Pengolahan Data dengan Orange Data Mining, pada tahap ini dilakukan import dataset ke dalam platform Orange Data Mining. Pada tahap ini juga dilakukan pemilihan atribut yang relevan untuk pembentukan model. Pada tahap ini juga dibangun alur kerja (workflow) untuk pengolahan data menggunakan algoritma Convolutional Neural Network (CNN) dengan arsitektur VGG-16.
- Pembentukan Model CNN, pada tahap ini digunakan Orange Data Mining untuk membangun arsitektur CNN. Model yang dibangun juga diatur parameter-parameter seperti jumlah lapisan konvolusi, ukuran kernel, dan fungsi aktivasi. Pada tahap ini digunakan lapisan MaxPooling untuk mereduksi dimensi data.
- Pelatihan Model, dimana pada tahap ini digunakan data pelatihan untuk melatih model CNN. Pada tahap ini dilakukan pemantauan metrik kinerja seperti akurasi dan loss. Pada tahap ini juga dilakukan penyesuaian parameter dan arsitektur model jika hasil pelatihan belum memuaskan.
- Evaluasi Model, pada tahap ini dilakukan pengujian menggunakan data pengujian yang terpisah untuk mengevaluasi kinerja model yang telah dilatih. Pada tahap ini dilakukan perhitungan metrik evaluasi seperti akurasi, presisi, recall, dan F1-score untuk masing-masing label.
- Analisis Hasil, pada tahap ini dilakukan analisis hasil metrik evaluasi untuk masing-masing kategori ikan. Pada tahap ini juga dilakukan identifikasi label yang memiliki performa baik dan label yang mungkin memerlukan peningkatan.

- h. Penyempurnaan dan Pemodelan Ulang, dimana penyempurnaan dilakukan apabila hasil evaluasi belum memuaskan, dimana penyempurnaan dilakukan pada prapemrosesan data, atau menyesuaikan parameter dan arsitektur model.
- i. Pembahasan dan Kesimpulan, dimana pada tahap ini dilakukan pembahasan hasil penelitian, termasuk interpretasi metrik evaluasi dan performa model. Pada tahap ini juga dilakukan penarikan kesimpulan tentang efektivitas penggunaan algoritma Convolutional Neural Network dengan arsitektur VGG-16 untuk klasifikasi citra ikan.
- j. Penulisan Laporan, dimana pada tahap ini dilakukan penyusunan laporan penelitian yang mencakup semua tahapan di atas.

2.2 Dataset

Dataset yang digunakan dalam penelitian ini yaitu data yang berupa citra gambar ikan yang terdiri dari 1088 total data training dan 215 total data testing. Kelas atau label yang ada dalam penelitian ini berjumlah 4 label jenis ikan, yaitu Bangus, Glass Perchlet, Gold Fish dan Gourami. Adapun rincian dataset dapat dilihat pada tabel berikut:

Tabel 1. Dataset

Jenis Data	Label	Jumlah Data	Total Data
Data Training	Bangus	171	1088
	Glass Perchlet	399	
	Gold Fish	201	
	Gourami	312	
Data Testing	Bangus	34	215
	Glass Perchlet	77	
	Gold Fish	40	
	Gourami	63	

Pada tabel 1 dapat dilihat komposisi daripada dataset yang digunakan, dimana dalam penelitian ini digunakan sebanyak 1088 data citra ikan yang sebagai data training untuk melatih model CNN dengan arsitektur VGG-16. Data testing digunakan untuk melakukan validasi terhadap model yang telah ditraining untuk melihat tingkat akurasi model dalam melakukan klasifikasi. Adapun data testing yang digunakan terdiri dari 215 total data testing. Adapun dataset yang digunakan tersebar dalam 4 buah label jenis ikan.

2.3 Convolutional Neural Network

Convolutional Neural Network (CNN) adalah jenis arsitektur jaringan saraf tiruan yang dirancang khusus untuk mengatasi tugas-tugas analisis visual, seperti pengenalan pola dalam citra dan pengolahan gambar. CNN memiliki struktur yang terinspirasi oleh cara kerja sistem penglihatan manusia, di mana lapisan-lapisan konvolusi dan penyetakan (pooling) digunakan untuk secara efektif mengekstraksi fitur-fitur penting dari citra. Adapun elemen dari CNN adalah sebagai berikut [22]–[25]:

- a. Konvolusi, operasi konvolusi adalah langkah penting dalam CNN. Konvolusi didefinisikan sebagai perhitungan produk titik antara filter (kernel) yang kecil dan citra input. Filter ini bergerak melintasi citra, dan pada setiap lokasi, elemen-elemen filter dikalikan dengan nilai-nilai piksel di lokasi yang bersesuaian di citra [26]. Dalam bentuk matematika, konvolusi 2D antara citra I dan filter K di lokasi (i,j) dinyatakan sebagai:

$$(I * K)_{ij} = \sum_m \sum_n I_{(i-m)(j-n)} K_{mn} \quad (1)$$

- b. Lapisan Konvolusi, lapisan konvolusi dalam CNN terdiri dari sejumlah filter yang masing-masing berperan dalam mengenali pola tertentu dalam citra. Filter-filter ini diterapkan pada seluruh citra, menghasilkan peta fitur (feature maps) yang mencatat aktivasi pada setiap lokasi [27]. Setiap peta fitur dihitung menggunakan operasi konvolusi.
- c. Penyetakan (Pooling), lapisan penyetakan (pooling) digunakan untuk mengurangi dimensi spasial dari peta fitur, sehingga mengurangi kompleksitas dan parameter model. MaxPooling adalah operasi umum yang diambil dari setiap area dalam peta fitur untuk menghasilkan nilai maksimum [28]. Operasi MaxPooling 2D pada area 2×2 di peta fitur F pada lokasi (i,j) dinyatakan sebagai:

$$\text{MaxPooling}(F)_{ij} = \max(F_{2i,2j}, F_{2i,2j+1}, F_{2i+1,2j}, F_{2i+1,2j+1}) \quad (2)$$

- d. Lapisan Fully Connected, setelah ekstraksi fitur melalui lapisan konvolusi dan penyetakan, hasilnya dihubungkan ke lapisan-lapisan fully connected seperti dalam jaringan saraf biasa. Lapisan-lapisan ini menghubungkan semua fitur yang dihasilkan ke dalam neuron-neuron yang kemudian menghasilkan probabilitas kelas-kelas.
- e. Fungsi Aktivasi, pada setiap neuron dalam jaringan, fungsi aktivasi non-linear seperti Rectified Linear Unit (ReLU) diterapkan untuk memperkenalkan elemen non-linearitas [29], [30]. Persamaan ReLU dinyatakan sebagai:

$$\text{ReLU}(x) = \max(0, x) \quad (3)$$

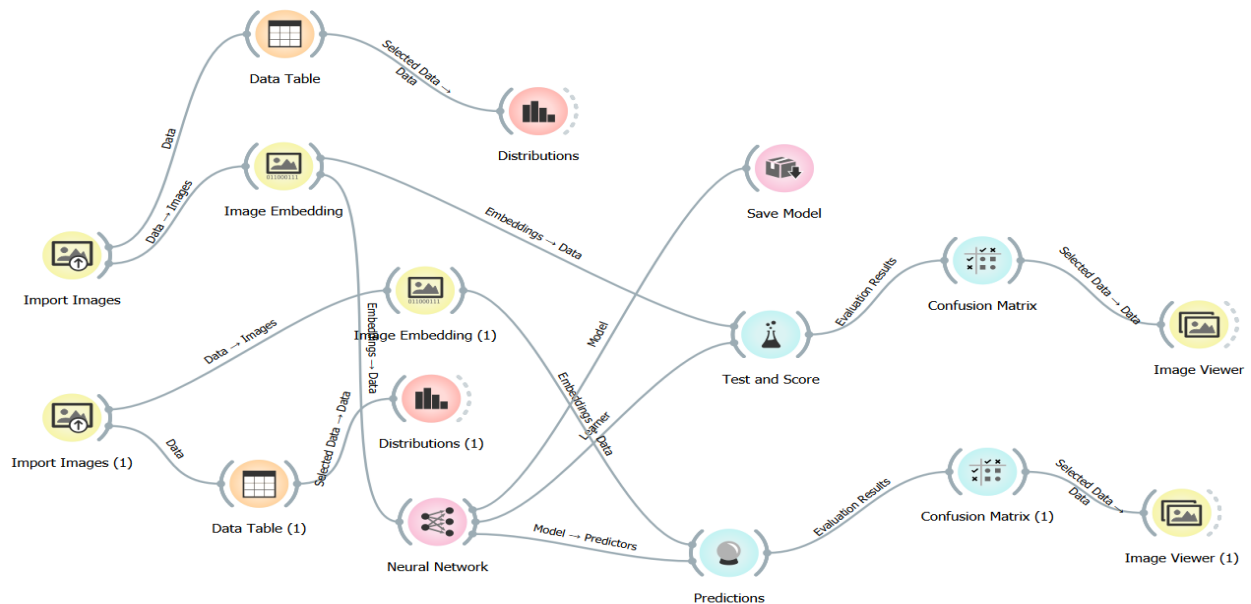
- f. Pelatihan dan Pembelajaran, pelatihan CNN melibatkan pengoptimalan parameter-parameter model menggunakan metode penurunan gradien (gradient descent) dengan meminimalkan fungsi kerugian (loss function). Backpropagation

digunakan untuk menghitung gradien fungsi kerugian terhadap parameter-parameter, dan algoritma optimasi seperti SGD (Stochastic Gradient Descent), Adam, atau RMSProp digunakan untuk memperbarui parameter-parameter [31]–[36].

3. HASIL DAN PEMBAHASAN

3.1 Model CNN dengan Arsitektur VGG-16

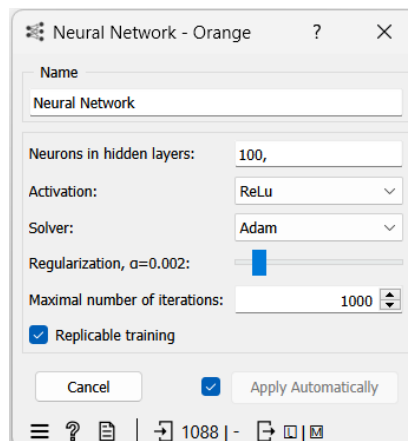
Model klasifikasi citra ikan menggunakan Convolutional Neural Network menggunakan arsitektur VGG-16 dirancang menggunakan tool Orange Data Mining untuk proses perhitungan datanya. Model dibangun dengan beberapa tahapan sesuai dengan gambar berikut:



Gambar 2. Perancangan Model CNN – VGG16

Model CNN dengan arsitektur VGG-16 dibangun dengan tool Orange Data Mining melalui beberapa tahapan, diantaranya yaitu:

- Import Image, dimana pada tahap ini dilakukan import seluruh dataset kedalam model. Import image dilakukan pada data training dan data testing.
- Image Embedding, dimana pada tahap ini dilakukan proses image embedding pada Orange Data Mining menggunakan VGG-16 melibatkan penggunaan arsitektur Convolutional Neural Network ini sebagai ekstraktor fitur pada citra. VGG-16 mengambil data citra ikan sebagai input, dan melalui serangkaian lapisan konvolusi dan aktivasi, menghasilkan representasi fitur yang mendalam dan semantik dari citra tersebut. Pada tahap ini, VGG-16 bertindak sebagai "encoder" yang mengubah citra menjadi vektor fitur yang lebih kompak dan informatif. Hasil embedding ini nantinya akan digunakan sebagai data untuk klasifikasi menggunakan CNN.
- Neural Network, pada tahap ini ditambahkan widget untuk CNN dengan beberapa parameter yang di setting. Adapun parameter CNN yang digunakan dapat dilihat pada gambar berikut:



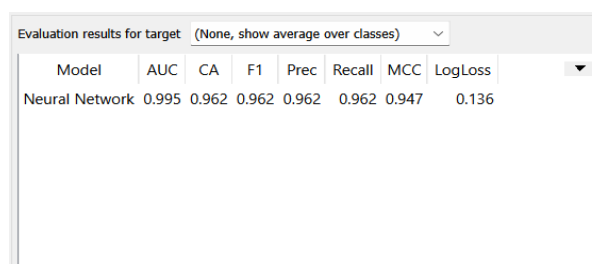
Gambar 3. Parameter Neural Network

CNN yang dibangun menggunakan beberapa parameter dasar dan parameter optimasi yaitu Neuron in Hidden Layer sebesar 100, Fungsi Aktivasi menggunakan ReLU, optimisasi model menggunakan Adam Optimizer, Regularization menggunakan value 0,002 serta maximal number of iteration menggunakan nilai 1000.

3.2 Hasil yang didapatkan

Berdasarkan model yang dibangun menggunakan beberapa parameter yang telah disebutkan pada bagian sebelumnya, maka didapatkan hasil melalui beberapa proses evaluasi yaitu sebagai berikut:

- Test and Score, dimana tahap ini dilakukan perhitungan akurasi training menggunakan Random Sampling, dengan training set size sebesar 80%. Pada tahap ini didapatkan hasil evaluasi training seperti pada gambar berikut:

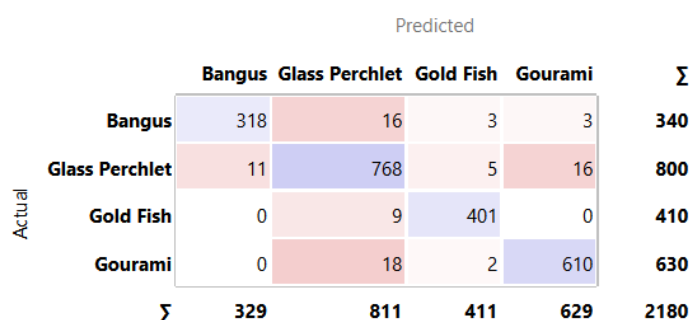


Model	AUC	CA	F1	Prec	Recall	MCC	LogLoss
Neural Network	0.995	0.962	0.962	0.962	0.962	0.947	0.136

Gambar 4. Hasil Evaluasi Training

Pada tahap ini didapatkan akurasi training yang cukup baik, dimana akurasi klasifikasi didapatkan sebesar 96,2%, dengan F1 Score sebesar 0,962 dan LogLoss sebesar 0,136.

- Confusion Matrix, dimana akurasi training dapat dilihat hasilnya menggunakan confusion matrix yang berisi informasi mengenai keberhasilan model dalam mengenal kelas daripada data citra yang diimport. Adapun hasil confusion matrix dapat dilihat pada gambar berikut:

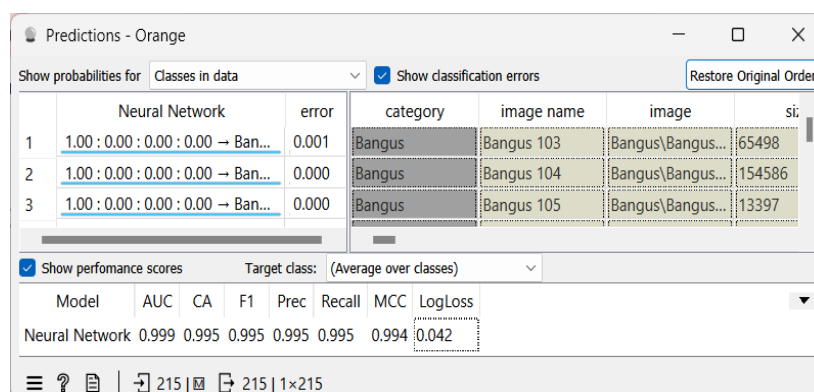


		Predicted				Σ
		Bangus	Glass Perchlet	Gold Fish	Gourami	
Actual	Bangus	318	16	3	3	340
	Glass Perchlet	11	768	5	16	800
	Gold Fish	0	9	401	0	410
	Gourami	0	18	2	610	630
Σ		329	811	411	629	2180

Gambar 5. Confusion Matrix untuk Proses Training

Pada confusion matrix dapat dilihat bahwa model secara garis besar berhasil mengenali label jenis ikan dengan baik, dengan rata-rata keberhasilan untuk semua label adalah sebesar 96,2%. Pada tahap ini dapat dilihat ada beberapa kesalahan prediksi label yang dilakukan oleh model yang dibangun. Pada proses training, model berhasil memprediksi 318 data Bangus dari total 340 data, 768 Glass Perchlet dari total 800 data, 401 jenis Gold Fish dari 410 total data dan 610 jenis Gourami dari 630 total data.

- Prediction, pada tahap ini dilakukan evaluasi keberhasilan model dengan cara menggunakan data testing untuk menguji akurasi model, dimana data testing ini merupakan data yang belum pernah digunakan sebelumnya pada proses training. Adapun hasil dari evaluasi model menggunakan data testing dapat dilihat pada gambar berikut:



Predictions - Orange						
Show probabilities for		Classes in data	<input checked="" type="checkbox"/> Show classification errors		Restore Original Order	
	Neural Network	error	category	image name	image	si:
1	1.00 : 0.00 : 0.00 : 0.00 → Ban...	0.001	Bangus	Bangus 103	Bangus\Bangus...	65498
2	1.00 : 0.00 : 0.00 : 0.00 → Ban...	0.000	Bangus	Bangus 104	Bangus\Bangus...	154586
3	1.00 : 0.00 : 0.00 : 0.00 → Ban...	0.000	Bangus	Bangus 105	Bangus\Bangus...	13397

Show performance scores		Target class: (Average over classes)					
Model	AUC	CA	F1	Prec	Recall	MCC	LogLoss
Neural Network	0.999	0.995	0.995	0.995	0.995	0.994	0.042

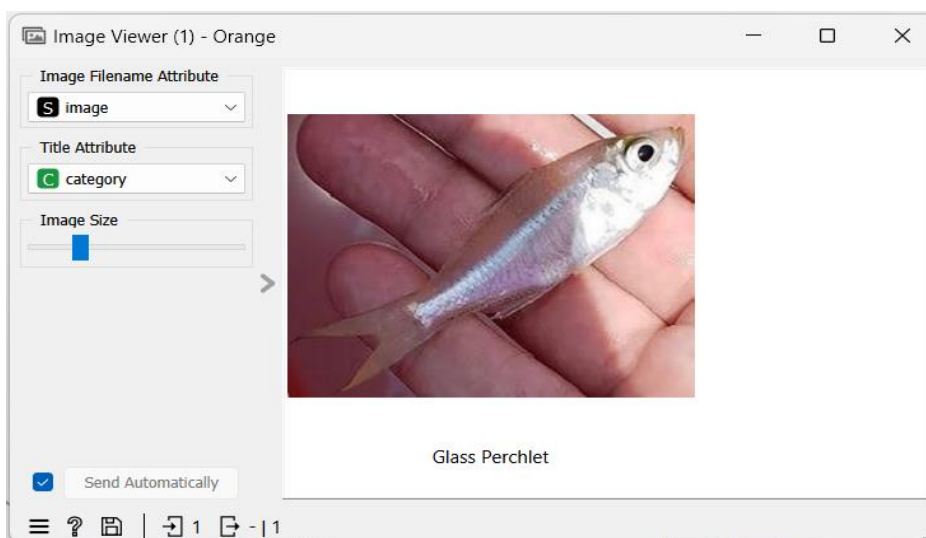
Gambar 6. Hasil Evaluasi Model

Pada proses evaluasi model didapatkan hasil yaitu model dapat melakukan klasifikasi dengan baik, dengan tingkat akurasi testing sebesar 99,5%, dengan nilai F1 Score sebesar 0,995 dan LogLoss sebesar 0,042. Hasil akurasi model juga dapat dilihat melalui confusion matrix untuk proses testing menggunakan data test seperti yang ditunjukkan pada gambar berikut:

		Predicted				
		Bangus	Glass Perchlet	Gold Fish	Gourami	Σ
Actual	Bangus	34	0	0	0	34
	Glass Perchlet	1	76	0	0	77
	Gold Fish	0	0	41	0	41
	Gourami	0	0	0	63	63
Σ		35	76	41	63	215

Gambar 7. Hasil Confusion Matrix untuk Proses Klasifikasi

Pada gambar tersebut dapat dilihat akurasi klasifikasi dimana model berhasil mengenali label dari data yang diberikan dengan akurasi sebesar 99,5%. Pada confusion matrix proses klasifikasi, dapat dilihat bahwa model hanya gagal mengenali label 1 data ikan, yaitu 1 jenis ikan Glass Perchlet namun dikenali sebagai Bangus. Berikut adalah hasil kesalahan prediksi yang dilakukan oleh model yang dibangun:



Gambar 8. Data Ikan yang Salah Diprediksi oleh Model

Gambar 8 menunjukkan hasil kesalahan prediksi yang dilakukan oleh model yang dibangun, dimana model memprediksi Glass Perchlet sebagai Bangus. Hal ini mungkin dikarenakan dari proses training mengenali jenis Bangus dengan salah satu ciri-cirinya yaitu sisik yang berwarna perak, juga bentuk dari Bangus yang memiliki tubuh lonjong, sehingga model menganggap 1 data Glass Perchlet ini sebagai jenis Bangus juga, dikarenakan karakteristiknya yang sangat serupa dengan karakteristik jenis Bangus.

4. KESIMPULAN

Berdasarkan penelitian yang telah dilakukan melalui proses yang telah disebutkan pada bagian sebelumnya, maka dapat ditarik beberapa kesimpulan dimana Model CNN dengan arsitektur VGG-16 yang dibangun telah berhasil melakukan klasifikasi citra ikan berdasarkan labelnya dengan baik dengan tingkat akurasi pada saat training sebesar 96,2% dan akurasi sebesar 99,5% pada saat pengujian menggunakan data testing. Pada saat training, model CNN – VGG16 yang dibangun berhasil memprediksi 318 data Bangus dari total 340 data, 768 Glass Perchlet dari total 800 data, 401 jenis Gold Fish dari 410 total data dan 610 jenis Gourami dari 630 total data, dengan tingkat akurasi rata-rata untuk semua label adalah sebesar 96,2%, dengan F1 score sebesar 0,962, dan LogLoss sebesar 0,136. Sedangkan pada saat proses testing menggunakan data yang belum pernah digunakan untuk proses training, didapatkan hasil yaitu hanya 1 data dari total 215 data testing yang salah diprediksi oleh model yang dibangun. Adapun kesalahan tersebut adalah 1 jenis ikan Glass Perchlet yang diprediksi sebagai Bangus. Adapun rata-rata akurasi untuk semua label ikan pada proses evaluasi model menggunakan data testing adalah sebesar 99,5%, dengan F1 score sebesar 0,995 dan LogLoss sebesar 0,042.

REFERENCES

- [1] X. Feng, Y. Jiang, X. Yang, M. Du, and X. Li, "Computer vision algorithms and hardware implementations: A survey," *Integration*, vol. 69, 2019. doi: 10.1016/j.vlsi.2019.07.005.
- [2] M. H. Guo et al., "Attention mechanisms in computer vision: A survey," *Computational Visual Media*, vol. 8, no. 3, 2022. doi: 10.1007/s41095-022-0271-y.
- [3] M. Abdullah-Al-Noman, A. N. Eva, T. B. Yeahyea, and R. Khan, "Computer Vision-based Robotic Arm for Object Color, Shape, and Size Detection," *Journal of Robotics and Control (JRC)*, vol. 3, no. 2, 2022, doi: 10.18196/jrc.v3i2.13906.
- [4] A. Sophokleous, P. Christodoulou, L. Doitsidis, and S. A. Chatzichristofis, "Computer vision meets educational robotics," *Electronics (Switzerland)*, vol. 10, no. 6, 2021. doi: 10.3390/electronics10060730.
- [5] I. Muslem, "Prototipe Kunci RFID (Radio Frequency Identification) dalam Meningkatkan Keamanan Kendaraan Bermotor," *JURNAL TIKA*, vol. 5, no. 3, 2021, doi: 10.51179/tika.v5i3.104.
- [6] L. Chen, S. Li, Q. Bai, J. Yang, S. Jiang, and Y. Miao, "Review of image classification algorithms based on convolutional neural networks," *Remote Sensing*, vol. 13, no. 22, 2021. doi: 10.3390/rs13224712.
- [7] E. Riana, "Penerapan Sensor Ultrasonic SRF05 Berbasis Mikrocontroller ATmega 8535 Untuk Sistem Pengereman Otomatis," *Journal of Information System Research (JOSH)*, vol. 2, no. 4, 2021, doi: 10.47065/josh.v2i4.761.
- [8] B. P. Kumar, "Minimum Distance Warning and Braking System for Vehicles," *Int J Res Appl Sci Eng Technol*, vol. 9, no. VI, 2021, doi: 10.22214/ijraset.2021.35506.
- [9] P. P. Freitas et al., "Giant magnetoresistive sensors for rotational speed control," *J Appl Phys*, vol. 85, no. 8 II B, 1999, doi: 10.1063/1.369975.
- [10] S. J. Anand, A. M. Kumar, Mahendran, K. Pugalarasu, and K. Surya, "Drowsy and Drunken Drive Control, Automatic Accident Detection and Rescue System Using Arduino," *International Journal of Scientific Development and Research*, vol. 5, no. 12, 2020.
- [11] A. Rahman, A. K. M. Mohiuddin, and A. Sakif, "Development of electro-hydro automatic parking braking system for automotive system," *International Journal of Recent Technology and Engineering*, vol. 7, no. 6, 2019.
- [12] A. V. Postolit, "Prospects for the Use of Artificial Intelligence and Computer Vision in Transport Systems and Connected Cars," *World of Transport and Transportation*, vol. 19, no. 1, 2021, doi: 10.30932/1992-3252-2021-19-1-74-90.
- [13] C. McCarroll and F. Cugurullo, "No city on the horizon: Autonomous cars, artificial intelligence, and the absence of urbanism," *Frontiers in Sustainable Cities*, vol. 4, 2022, doi: 10.3389/frsc.2022.937933.
- [14] B. Padmaja, C. V. K. N. S. N. Moorthy, N. Venkateswarulu, and M. M. Bala, "Exploration of issues, challenges and latest developments in autonomous cars," *J Big Data*, vol. 10, no. 1, 2023, doi: 10.1186/s40537-023-00701-y.
- [15] R. Hussain and S. Zeadally, "Autonomous Cars: Research Results, Issues, and Future Challenges," *IEEE Communications Surveys and Tutorials*, vol. 21, no. 2, 2019. doi: 10.1109/COMST.2018.2869360.
- [16] P. P. Em, J. Hossen, I. Fitriani, and E. K. Wong, "Vision-based lane departure warning framework," *Heliyon*, vol. 5, no. 8, 2019, doi: 10.1016/j.heliyon.2019.e02169.
- [17] W. Chen, W. Wang, K. Wang, Z. Li, H. Li, and S. Liu, "Lane departure warning systems and lane line detection methods based on image processing and semantic segmentation: A review," *Journal of Traffic and Transportation Engineering (English Edition)*, vol. 7, no. 6, 2020. doi: 10.1016/j.jtte.2020.10.002.
- [18] J. M. Clanton, D. M. Bevy, and A. S. Hodel, "A low-cost solution for an integrated multisensor lane departure warning system," *IEEE Transactions on Intelligent Transportation Systems*, vol. 10, no. 1, 2009, doi: 10.1109/TITS.2008.2011690.
- [19] J. Wu, H. Xu, and J. Zhao, "Automatic Lane Identification Using the Roadside LiDAR Sensors," *IEEE Intelligent Transportation Systems Magazine*, vol. 12, no. 1, 2020, doi: 10.1109/ITS.2018.2876559.
- [20] K. Simonyan and A. Zisserman, "VGG-16," *arXiv preprint*, 2014.
- [21] D. Theckedath and R. R. Sedamkar, "Detecting Affect States Using VGG16, ResNet50 and SE-ResNet50 Networks," *SN Comput Sci*, vol. 1, no. 2, 2020, doi: 10.1007/s42979-020-0114-9.
- [22] L. Mohammadpour, T. C. Ling, C. S. Liew, and A. Aryanfar, "A Survey of CNN-Based Network Intrusion Detection," *Applied Sciences (Switzerland)*, vol. 12, no. 16, 2022. doi: 10.3390/app12168162.
- [23] N. Gozzi et al., "Image Embeddings Extracted from CNNs Outperform Other Transfer Learning Approaches in Classification of Chest Radiographs," *Diagnostics*, vol. 12, no. 9, 2022, doi: 10.3390/diagnostics12092084.
- [24] M. Jiang, P. Wu, and F. Li, "Detecting dark spot eggs based on CNN GoogLeNet model," *Wireless Networks*, 2021, doi: 10.1007/s11276-021-02673-4.
- [25] S. H. Noh, "Performance comparison of CNN models using gradient flow analysis," *Informatics*, vol. 8, no. 3, 2021, doi: 10.3390/informatics8030053.
- [26] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2015. doi: 10.1109/CVPR.2015.7298965.
- [27] T. C. Lu, "CNN Convolutional layer optimisation based on quantum evolutionary algorithm," *Conn Sci*, vol. 33, no. 3, 2021, doi: 10.1080/09540091.2020.1841111.
- [28] W. Yuan, B. Dong, S. Wang, M. Unoki, and W. Wang, "Evolving multi-resolution pooling cnn for monaural singing voice separation," *IEEE/ACM Trans Audio Speech Lang Process*, vol. 29, 2021, doi: 10.1109/TASLP.2021.3051331.
- [29] D. Boob, S. S. Dey, and G. Lan, "Complexity of training ReLU neural network," *Discrete Optimization*, vol. 44, 2022, doi: 10.1016/j.disopt.2020.100620.
- [30] Q. Gong, W. Kang, and F. Fahroo, "Approximation of compositional functions with ReLU neural networks," *Syst Control Lett*, vol. 175, 2023, doi: 10.1016/j.sysconle.2023.105508.
- [31] R. Elshamy, O. Abu-Elnasr, M. Elhoseny, and S. Elmougy, "Improving the efficiency of RMSProp optimizer by utilizing Nestrovo in deep learning," *Sci Rep*, vol. 13, no. 1, 2023, doi: 10.1038/s41598-023-35663-x.
- [32] D. Xu, S. Zhang, H. Zhang, and D. P. Mandic, "Convergence of the RMSProp deep learning method with penalty for nonconvex optimization," *Neural Networks*, vol. 139, 2021, doi: 10.1016/j.neunet.2021.02.011.

- [33] V. V. Ramalingam and R. Ragavendran, "Prediction of liver disease using artificial neural network with adam optimizer," *Journal of Critical Reviews*, vol. 7, no. 17, 2020, doi: 10.31838/jcr.07.17.164.
- [34] Z. Zhang, "Improved Adam Optimizer for Deep Neural Networks," in *2018 IEEE/ACM 26th International Symposium on Quality of Service, IWQoS 2018*, 2019. doi: 10.1109/IWQoS.2018.8624183.
- [35] J. H. Friedman, "Stochastic gradient boosting," *Comput Stat Data Anal*, vol. 38, no. 4, 2002, doi: 10.1016/S0167-9473(01)00065-2.
- [36] S. Klein, J. P. W. Pluim, M. Staring, and M. A. Viergever, "Adaptive stochastic gradient descent optimisation for image registration," *Int J Comput Vis*, vol. 81, no. 3, 2009, doi: 10.1007/s11263-008-0168-y.